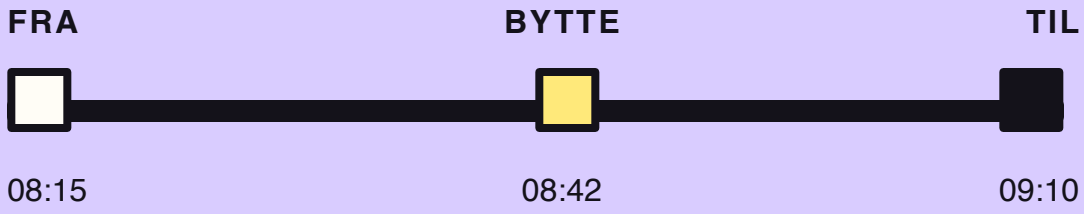
TEKNISK DEMO · FYRÎ · 24.10.26

Reisesøk med beslutningsmodeller

Søk med naturlig språk

John-Olav Storvold
Knowit



OM MEG

John-Olav Storvold



Senior fullstackutvikler

Knowit ~~Data & Tech~~ **Solutions Consulting**

ReiseInfo hos Tet Digital

Reiseplanlegger med høy trafikk i flere regioner

Reisesøk med fritekst

Prosjekt på siden, bygget på åpne Entur-data

PROBLEMET

Reisesøk i dag er et skjema

Fra	Til	Dato	Tid	Filtre

«Jeg må være på Majorstuen før klokka åtte i morgen.»

Brukeren må oversette behovet sitt til felt, klokkeslett og filtre. Jo flere valg, jo mer arbeid.

IDEEN

Beskriv reisen.

Modellen tar valgene.

Fritekst inn, strukturert svar ut.

BLODFERSKT

Beslutningsmodeller er helt nytt

Modell	Fra	Lansert	Tilgang
Jev	TypeSafe AI	15. sep. 2026	Administrert API
Laya	Convai Innovations	Sep. 2026	Åpne vekter, Apache 2.0
Clef	Cloudflare	1. okt. 2026	Åpne vekter, Apache 2.0

Jev, Laya og Clef kom alle i løpet av noen uker, høsten 2026.

Kilder: Runware, Towards AI, Cloudflare. Tall oppgitt av leverandørene.

BESLUTNINGSMODELLER

Hva er en beslutningsmodell?

Velger, skriver ikke

Modellen får en tilstand i fritekst og et spørsmål. Den velger blant svarene vi gir den.

Strukturerte data ut

Svaret er data koden bruker direkte, ikke tekst som må tolkes.

{"to": "Majorstuen", "time_mode": "arrive_by"}

Sannsynligheter ut

Kalibrerte sannsynligheter som koden kan sette terskel på eller bruke til ruting.

Fart er en viktig egenskap

Én runde uten tekstgenerering gir svar på millisekunder, ikke sekunder. Clef-flash: median 38,8 ms.

Eksempelet er illustrasjon. Kilder: Cloudflare Clef-blogg, Runware

BESLUTNINGSMODELLER

Tre spørsmålstyper

choice

Velg ett

Modellen peker på ett alternativ i en liste.

«Hvilket stopp skal du fra?» [A, B, C, ingen]

noul

Ja eller nei

Modellen gir sannsynligheten for ja. Koden setter terskelen.

«Inneholder reisesøket et avreisested?»

score

Gi poeng

Poeng i stedet for ett valg, for rangering eller terskel.

«Hvor godt passer hver rute?» [rute A, rute B, rute C]

Eksemplene er illustrasjoner. Vår kode bruker choice og noul. Kilde: Cloudflare, Runware

BESLUTNINGSMODELLER

Mageføelse mot resonnering

SYSTEM 1 · BESLUTNINGSMODELL

Mageføelse

Én runde, svar på ca. 40 millisekunder.

Velger fra en meny.

Trenger ferdige kandidater.

SYSTEM 2 · LLM

Resonnering

Steg for steg, token for token.

Skriver **fri** tekst og kan forklare seg.

Tregere og mer metodisk.

Mageføelse gjør valget. Resonnering skriver svaret.

Analogi fra Kahneman, ikke leverandørenes egen påstand.

BESLUTNINGSMODELLER

Slik virker den



Alle svar scores parallelt i én runde. Ingen tekst genereres, så svaret kan ikke bli ugyldig.

Eksempelet er illustrasjon. Kilde: Cloudflare Clef-blogg (1. okt. 2026)

BESLUTNINGSMODELLER

Beslutningsmodell eller LLM?

	LLM med JSON-modus	Beslutningsmodell
Utdata	Genereres token for token	Scores i én runde
Format	Kan bli ugyldig	Alltid ett av våre svar
Responstid	Sekunder	Millisekunder
Kjøring	Typisk sky-API	Kan kjøres lokalt
Krever	Gode instruksjoner	Ferdige kandidater

Rammeverk, ikke målt sammenligning. Responstid: Cloudflare, 2,2 s mot 4,7 s i én arbeidsflyt.

DEL 2

Fra teori til praksis

Så: hvordan bruker vi dette til reisesøk?

Live demo

VÅR LØSNING

Koden parser. Modellen velger.

1 FRITEKST

Reisesøk på norsk eller engelsk. Å dele posisjon er valgfritt.

→

2 KANDIDATER

Kode: fuzzy matching over ca. 51 000 stoppesteder, regex for tid

→

3 CLEF VELGER

Clef velger blant kandidatene. Kjører lokalt.

→

4 STRUKTURERT SVAR

from, to, time, mode

Clef er en lokal klassifikator, ikke en generator. Den svarer på valg, ja/nei og poeng.

RESULTATER

Hvor godt virker det?

91 %

Clef består 63 av 69 tester. Raskeste modell er ikke den beste.

Modell	Bestått	Tester	Snitt per søk
Clef-Flash	91 %	63/69	ca. 2 s
H2O-Lightning	81 %	56/69	ca. 1,2 s
d1-3B	70 %	48/69	ca. 0,65 s
Winnow-12B	64 %	44/69	ca. 3 s

Egen testsuite, 69 tilfeller, samme kandidater og spørsmål for alle. Tid målt på Mac M4 Max.

GRENSER

Hva du bør passe på

Typede svar er ikke immunitet

For Jev lyktes prompt injection i 1,8 % av 510 tilfeller, og i ca. 3,5 % med adaptive angrep.

Kandidatene må være gode

Modellen kan bare velge det koden legger frem. Feil kandidater gir feil svar.

Test på egne data

De fleste tall kommer fra leverandørene. Ingen kilder viser norsk ytelse.

Kilde: arXiv 2609.28613 (kun Jev), Runware, Cloudflare

OPPSUMMERT

Tre ting å ta med

1. Språk inn, struktur ut
2. Koden parser, modellen velger
3. Mål på egne data

Spørsmål?

PRØV SELV

QR kommer straks